Raport projekt 1 SIGK

Zadanie 1. Zwiększanie rozdzielczości

Zaproponowany model ResizeNet jest siecią konwolucyjną z blokami rezydualnymi, normalizacją, upsamplingiem przy użyciu PixelShuffle oraz połączeniu rezydualnym z interpolacją bikubiczną (dodanym na końcu).
Zastosowano złożoną funkcję straty, która łączy trzy różne podejścia do oceny jakości obrazu:

- błąd MSE,
- metrykę SSIM,
- metrykę LPIPS.

Funkcja straty ma postać:
$L = \lambda MSE \cdot LMSE + \lambda LPIPS \cdot LLPIPS + \lambda SSIM \cdot (1 - SSIM)$
gdzie:

- $\lambda MSE = 0.75$,
- $\lambda SSIM = 0.20$,
- $\lambda LPIPS = 0.05$.

Do tworzenia **danych wejściowych** wykorzystano bibliotekę OpenCV, funkcję cv2.resize z interpolacją cv2.INTER_CUBIC (bicubic).

Wyniki:
Dla obrazów wejściowych o rozmiarze 32x32:

Metoda	PSNR	SSIM	LPIPS
Bicubic interpolation	16.88	0.3472	0.8423
Model	17.39	0.3556	0.4557

Dla obrazów wejściowych o rozmiarze 64x64:

Metoda	PSNR	SSIM	LPIPS
Bicubic interpolation	19.07	0.4920	0.6164
Model	19.43	0.5057	0.2711

Model poprawia wszystkie metryki względem metody bazowej. Największa poprawa widoczna jest w metryce LPIPS → lepsza jakość wizualna.

Przykładowe wyniki
Dla obrazów wejściowych o rozmiarze 32x32:

Dla obrazów wejściowych o rozmiarze 64x64:

Zadanie 2. Odszumianie

Zastosowany model to DenoiseNet. Architektura jest oparta na BaseNet z blokami residualBlocks. Kazdy blok zawiera 2 warstwy konwolucji 3x3 + BatchNorm + LeakyReLu(0.2). Głównie jest to redukcja szumu przez ekstrakcję cech.

Zastosowano złożoną funkcję straty, która łączy trzy różne podejścia do oceny jakości obrazu:

- błąd MSE,
- metrykę SSIM,
- metrykę LPIPS.

Funkcja straty ma postać:
$L = \lambda MSE \cdot LMSE + \lambda LPIPS \cdot LLPIPS + \lambda SSIM \cdot (1-SSIM)$
gdzie:

- $\lambda MSE = 0.75$,
- $\lambda SSIM = 0.20$,
- $\lambda LPIPS = 0.05$.

Dodatkowo została obliczone SNE (Signal to noise energy) aby sprawdzić stosunek sygnału/szumu.

Wyniki:
Dla $\sigma = 0.01$

Method	PSNR	SSIM	LPIPS	SNE
Biliteral	27.57	0.9292	0.0819	15.21
Model	28.60	0.9449	0.0225	16.91

Model przy $\sigma = 0.01$ znacznie wygrywa względem biliteral w każdej metryce. Najwiekszą przewagę ma w LPIPS.

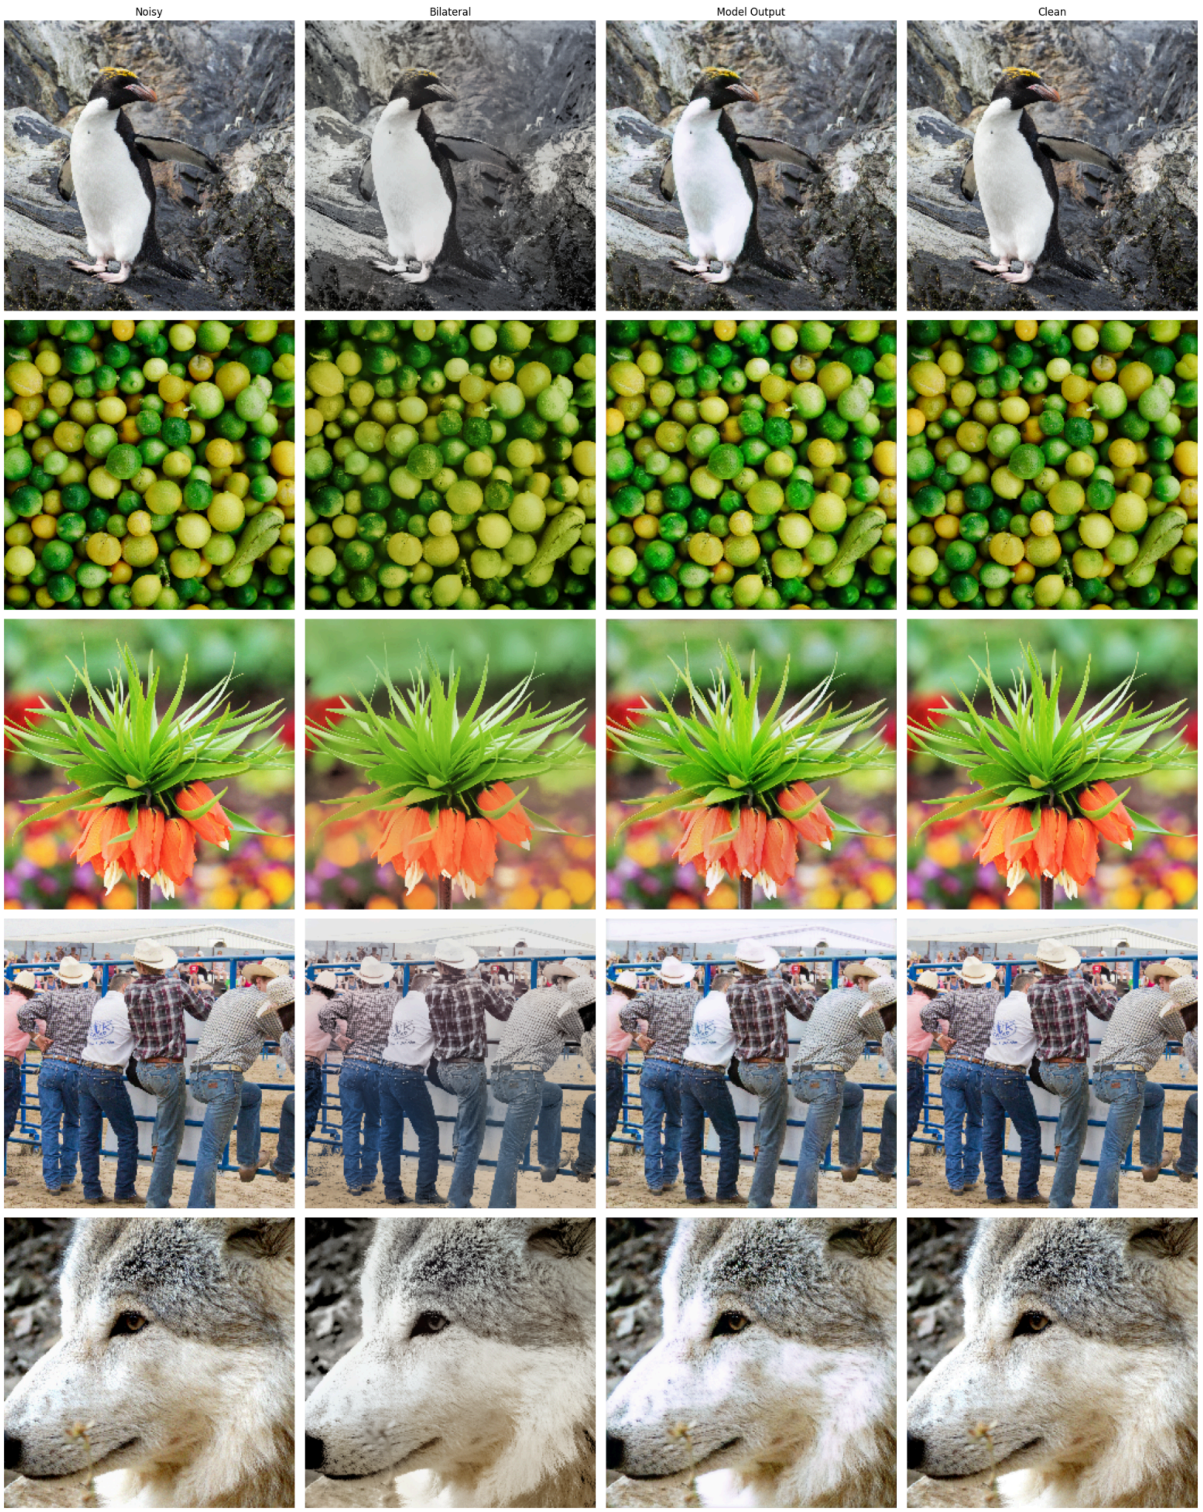

Dla σ = 0.03

Method	PSNR	SSIM	LPIPS	SNE
Biliteral	27.32	0.9065	0.0828	14.95
Model	26.87	0.9125	0.0376	15.18

Model przy σ = 0.03 ma lekko gorszy wskaźnik PSNR jednak nadal sprawdza się znacznie lepiej w innych wskaźnikach.

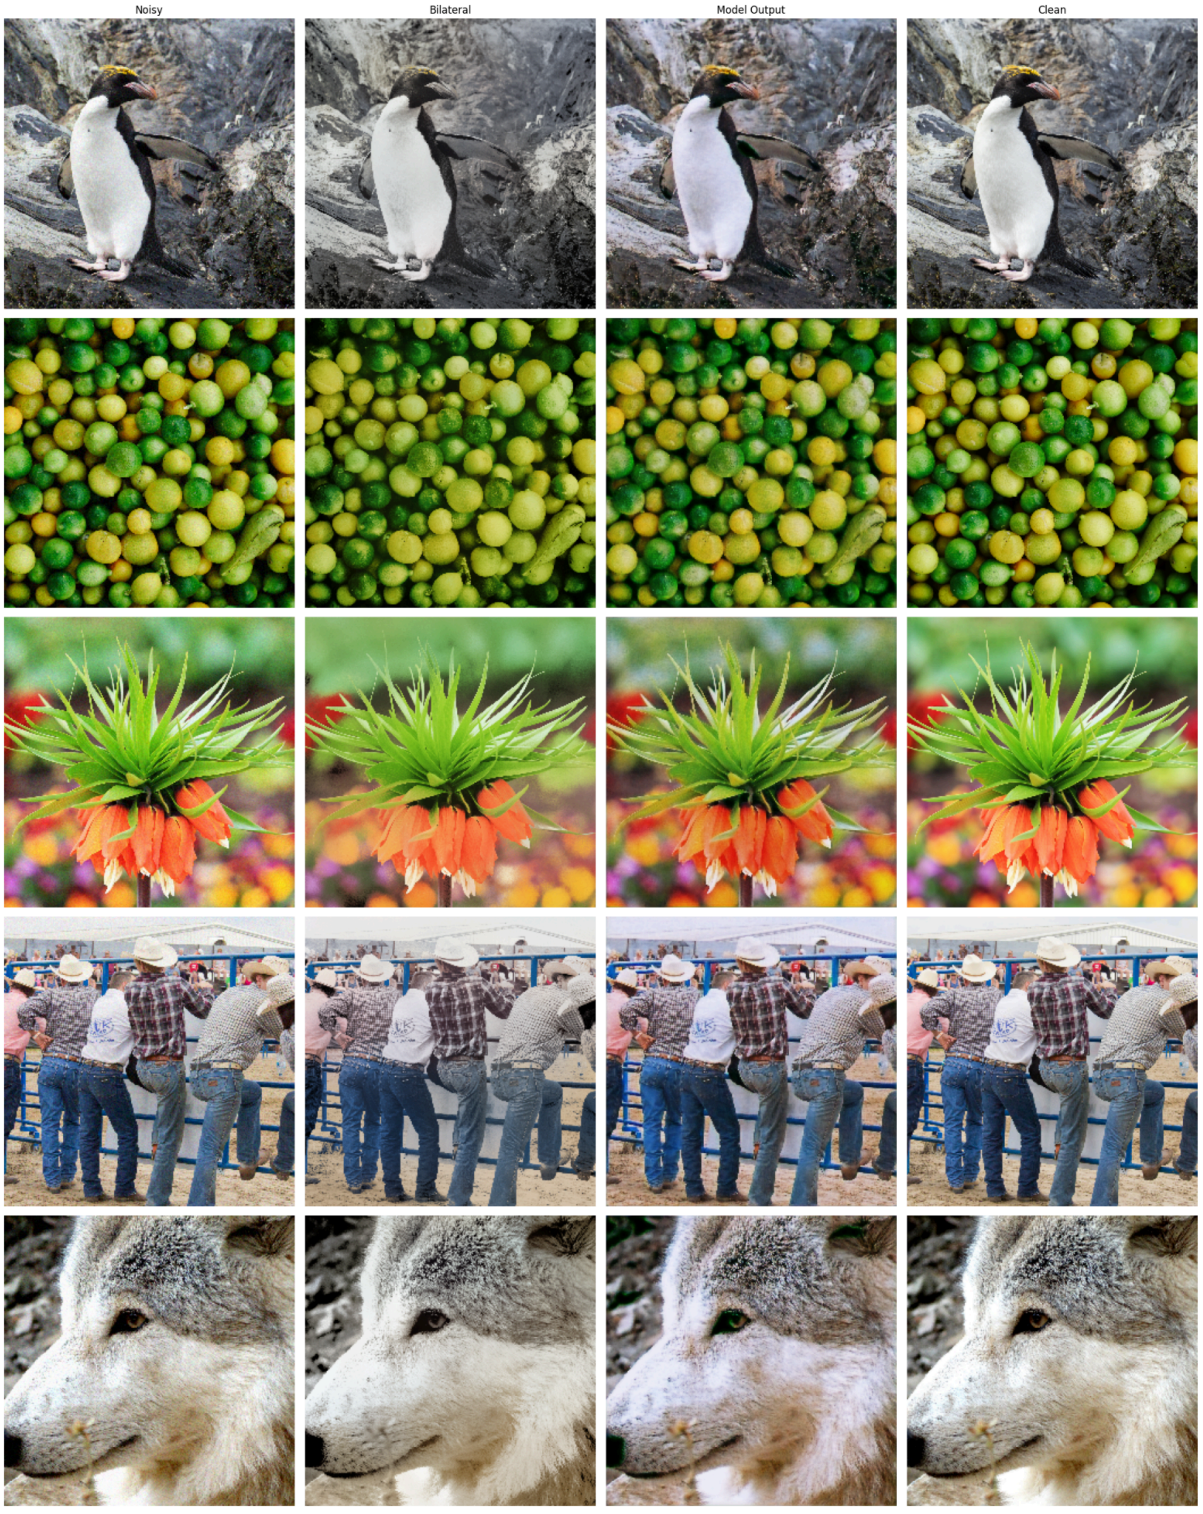
Noisy
Bilateral
Model Output
Clean